Politechnika Warszawska

WYDZIAŁ ELEKTRONIKI
I TECHNIK INFORMACYJNYCH



Instytut Informatyki

Sprawozdanie z realizacji projektu

Klasyfikacja emocji w tekście

Brygida Silawko

WARSZAWA 2026

Spis treści

1. Wstęp 3
2. Przegląd literatury 4
3. Opis rozwiązania 5
3.1. Wykorzystane biblioteki i narzędzia 5
3.2. Wykorzystany zbiór danych 5
3.3. Podejście 1: TF-IDF i sieć neuronowa (MLP) 6
3.3.1. Przebieg treningu EmotionNet 7
3.4. Podejście 2: Klasyfikator oparty o model DistilBERT-base-uncased . . . 7
3.4.1. Przebieg dostrajania 7
3.5. Podejście 3: Dostosowywanie modelu Qwen3-1.7B-base 8
3.5.1. Przebieg dostrajania LoRA 8
4. Wyniki ewaluacji eksperymentalnej 9
4.1. Metryki 10
4.2. Macierze pomyłek 11
4.3. Wizualizacje reprezentacji metodą UMAP 13
4.4. Omówienie wyników 13
5. Podsumowanie 15
Bibliografia 16

1. Wstęp

Klasyfikacja emocji w tekstach może być wykorzystywana m.in. w analizie opinii, monitorowaniu nastrojów społecznych lub algorytmach rekomendujących treści. Zadanie to jest szczególnie trudne, gdy tekst jest krótki i ma nieformalny charakter. Celem projektu jest porównanie skuteczności różnych metod klasyfikacji tekstu na zbiorze zawierającym wpisy z Twittera [1], które dobrze reprezentują wspomniane wyzwania.

Dane wejściowe	**Przypisana emocja**
when i heard a rumour that the st year exam results were out i had fear that i might be one of the failures	fear
i already have my christmas trees up i got two and am feeling festive which i m sure is spurring me to get started on this book	joy
i go online and i see a friend talking to another one and is not talking to me i feel ignored i feel unloved	sadness

Tabela 1.1. Przykładowe dane ze zbioru

W ramach projektu zaimplementowano i porównano skuteczność trzech podejść.

1. Ekstrakcja cech z tekstu metodą TF-IDF, a następnie wytrenowanie sieci neuronowej na wyznaczonych reprezentacjach
2. Klasyfikator probabilistyczny oparty o model DistilBERT-base-uncased
3. Dostosowanie modelu Qwen3-1.7B-Base do generowania odpowiedzi wskazującej klasę. Model był dostosowywany przy użyciu few-shot prompting oraz LoRA.

Dla każdego podejścia wyznaczono dokładność, czułość, f1-score i precyzję dla każdej z klas oraz macierz pomyłek na zbiorze treningowym i testowym. Dodatkowo wygenerowano wizualizację przestrzeni reprezentacji dla części zbioru testowego metodą UMAP.

2. Przegląd literatury

W podejściu 2 wykorzystano model DistilBERT-base-uncased [2], a w podejściu 3 model Qwen3-1.7B-base [3].

Użyty zbiór danych powstał na potrzeby pracy [1], gdzie zaproponowano metodę CARER (*Contextualized Affect Representations for Emotion Recognition*). Autorzy opracowali algorytm oparty na grafie. Pozwala on uzyskać bogate opisy struktury tekstu, które są następnie wykorzystywane do konstruowania reprezentacji uwzględniających kontekst. W pracy opisane jest również jako został utworzony zbiór danych. Pobrane z Twittera wpisy zostały automatycznie wyetykietowane na podstawie hashtagów.

3. Opis rozwiązania

3.1. Wykorzystane biblioteki i narzędzia

Kategoria	Biblioteki i narzędzia
Wizualizacja	`umap-learn`, `matplotlib`, `seaborn`
Zbiór danych	`datasets`
Tworzenie, trenowanie i dostosowywanie modeli	`torch`, `lightning`, `transformers`, `peft`, `bitsandbytes`, `accelerate`
Metryki	`torchmetrics`, `evaluate`, `scikit-learn`
Pomocnicze	`tqdm`, `numpy`, `pandas`, `colorama`, `wandb`, `scipy`

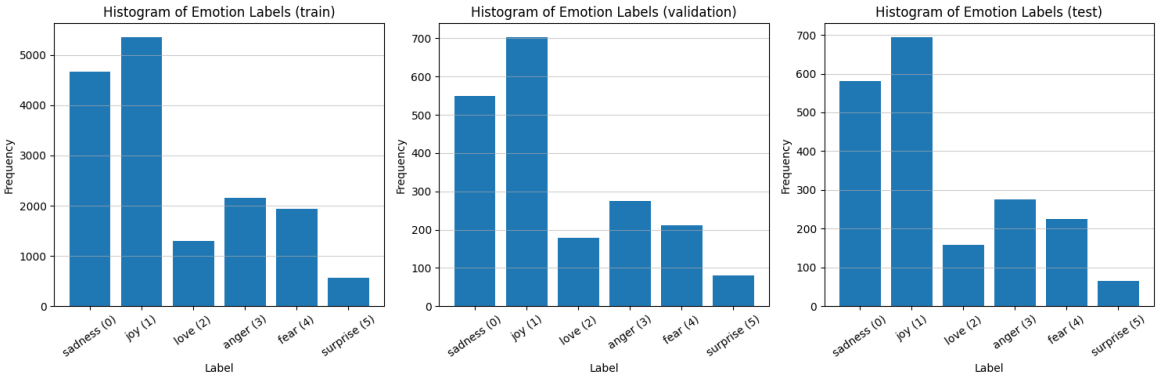
Tabela 3.1. Zestawienie wykorzystanych bibliotek i narzędzi.

3.2. Wykorzystany zbiór danych

Zbiór danych użyty w projekcie znajduje się na `https://huggingface.co/datasets/dair-ai/emotion`. Zbiór składa się z dwóch kolumn `text` - treść wpisu na Twitterze w języku angielskim oraz `label` - przypisana emocja w postaci wartości od 0 do 5. Mapowanie etykiet prezentuje się następująco:

- 0 – smutek (*sadness*),
- 1 – radość (*joy*),
- 2 – miłość (*love*),
- 3 – złość (*anger*),
- 4 – strach (*fear*),
- 5 – zaskoczenie (*surprise*).

Podział na część treningową, walidacyjną oraz testową został przyjęty taki jak na huggingface: zbiór treningowy - 16 tysięcy przykładów, zbiór walidacyjny - 2 tysiące przykładów, zbiór testujący - 2 tysiące przykładów. Rozkład klas w poszczególnych częściach prezentuje się następująco:

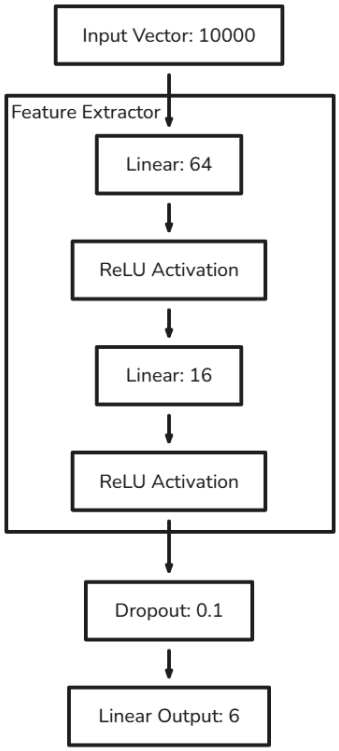


Rysunek 3.1. Rozkład klas w zbiorach

3.3. Podejście 1: TF-IDF i sieć neuronowa (MLP)

Dokonano ekstrakcji cech przy pomocy klasy `TfidfVectorizer` z biblioteki `scikit-learn` z parametrami:

- `max_features=10000`
- `lowercase=True`
- `analyzer='word'`
- `ngram_range=(1,2)`
- `stop_words='english'`



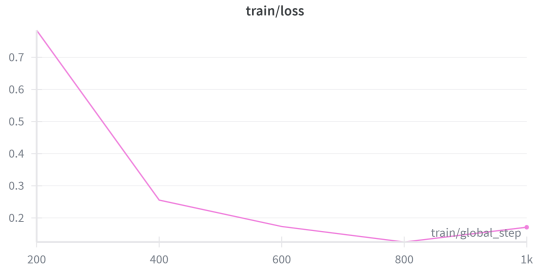
Rysunek 3.2. Schemat sieci neuronowej

Wyznaczenie cech i ich ekstrakcja została wykonana na zbiorze treningowym. Natomiast na zbiorach walidacyjnym i testowym dokonano jedynie ekstrakcji cech. Przetworzone zbiory przygotowano do uczenia sieci neuronowej poprzez opakowanie ich w klasę `torch.utils.data.DataLoader`. Sieć neuronowa została zaimplementowana przy pomocy biblioteki `pytorch` (implementacja w kodzie - klasa `EmotionNet`). Architektura utworzonej sieci neuronowej znajduje się na rysunku 3.2.

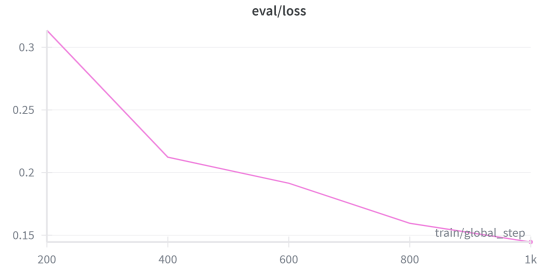
Uczenie sieci zostało wykonane przy pomocy biblioteki `lightning`. Do optymalizacji procesu uczenia wykorzystano `AdamW` oraz `lr_scheduler.CosineAnnealingLR` z `torch.optim`.

3.3.1. Przebieg treningu EmotionNet

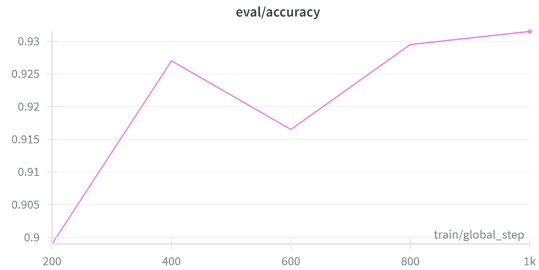
Podczas treningu monitorowane były wartości funkcji straty (entropia krzyżowa) oraz dokładność.



Rysunek 3.3. Training Loss



Rysunek 3.4. Validation Loss



Rysunek 3.5. Validation Accuracy

Rysunek 3.6. Wykresy przebiegu treningu EmotionNet

3.4. Podejście 2: Klasyfikator oparty o model DistilBERT-base-uncased

W podejściu 2 dostrajany był model `disitlbert-base-uncased` dostępny na huggingface (`https://huggingface.co/distilbert/distilbert-base-uncased`). Model został załadowany jako `AutoModelForSequenceClassification`, dzięki temu do bazowego modelu została dodana głowica klasyfikacji, predykująca klasę wyjściową. Do dostrojenia modelu została wykorzystana klasa `Trainer` z biblioteki `transformers`.

3.4.1. Przebieg dostrajania

Podczas dostrajania monitorowane były wartości funkcji straty (entropia krzyżowa) oraz dokładność.

Tabela 3.2. Procesu dostrajania modelu DistilBERT-base-uncased

Step	Training Loss	Validation Loss	Accuracy
200	0.7841	0.313556	0.8990
400	0.2555	0.212283	0.9270
600	0.1733	0.191464	0.9165
800	0.1250	0.159521	0.9295
1000	0.1268	0.144575	0.9315

3.5. Podejście 3: Dostosowywanie modelu Qwen3-1.7B-base

W podejściu 3 dostosowywany był model Qwen3-1.7B-base dostępny na `https://huggingface.co/Qwen/Qwen3-1.7B-Base`. Model został załadowany jako `AutoModelForCasualLM`. Sprawdzono dwie metody dostrajania:

- few-shot prompting
- LoRA

Prompt do testowania miał postać:

```
Your task is to analyze emotions in text.
Assign one of these 6 emotions: ['sadness', 'joy', 'love', 'anger',
'fear', 'surprise'] to the following text.
Answer only with one word from emotions list.
## Input Text: <tekst ze zbioru>
## Assigned emotion:
```

Natomiast do trenowania:

```
Your task is to analyze emotions in text.
Assign one of these 6 emotions: ['sadness', 'joy', 'love', 'anger',
'fear', 'surprise'] to the following text.
Answer only with one word from emotions list.
## Input Text: <tekst ze zbioru>
## Assigned emotion: <poprawna emocja ze zbioru> <|endoftext|>
```

Przy few-shot promptingu prompt do modelu został utworzony z 3 przykładów ze zbioru trenującego w formie promptu do trenowania oraz 1 promptu do testowania z tekstem ze zbioru testowego.

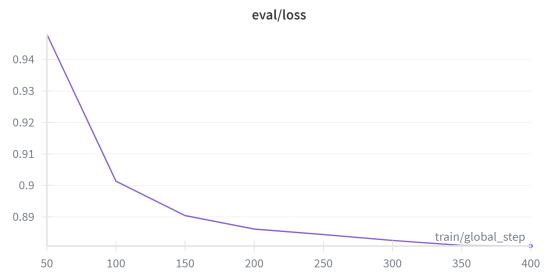
Do dostrajania metodą LoRA zastosowano parametry `r=8, lora_alpha=32`. Wejściem do modelu były prompty do trenowania. Modyfikowano warstwy liniowe modelu: `q_proj, k_proj, v_proj, o_proj, gate_proj, up_proj, down_proj`. Model był dostrajany przy pomocy klasy `Trainer` z biblioteki `transformers`.

3.5.1. Przebieg dostrajania LoRA

Podczas dostrajania monitorowane były wartości funkcji straty (entropia krzyżowa).



Rysunek 3.7. Training Loss



Rysunek 3.8. Validation Loss

Rysunek 3.9. Wykresy przebiegu dostrajania Qwen3-1.7B-base z LoRA

4. Wyniki ewaluacji eksperymentalnej

W celu oceny jakości zaimplementowanych rozwiązań wyznaczono:

- dla każdej z klas
  - precision
  - recall
  - f1-score
- accuracy
- macro avg precision, recall i f1-score
- weighted avg precision, recall i f1-score
- macierz pomyłek

Wszystkie oceny zostały wykonane raz dla zbioru trenującego i raz dla zbioru testowego. Wyjątkiem było sprawdzenie metody few-shot prompting dla Qwen3-1.7B, gdzie do przykładów w promptcie użyto przykładów ze zbioru treningowego a metodę sprawdzono tylko na zbiorze testowym. Dodatkowo przy badaniu jakości sprawdzono w ilu przypadkach model Qwen3 zwrócił jedną z 6 dopuszczalnych klas. Przykłady, gdzie tego nie zrobił nie były brane pod uwagę. Dla modelu dostosowanego metodą few-shot prompting odrzucono 3 przykłady, a dla modelu dostosowanego metodą LoRA 1 przykład z zbioru testowego i 6 ze zbioru trenującego.

Wygenerowano również wizualizację wyznaczonych reprezentacji na zbiorze testowym przy pomocy metody UMAP.

4.1. Metryki

Tabela 4.1. Porównanie F1-Score dla poszczególnych klas emocji

Model i Zbiór	sadness	joy	love	anger	fear	surprise
TF-IDF MLP (test)	0.91	0.91	0.68	0.86	0.86	0.11
DistilBERT (test)	**0.97**	**0.96**	**0.86**	**0.92**	**0.89**	**0.75**
Qwen Few-Shot (test)	0.50	0.68	0.29	0.48	0.36	0.16
Qwen LoRA (test)	0.68	0.76	0.30	0.56	0.55	0.00
DistilBERT (train)	**0.99**	0.97	**0.90**	0.97	0.94	**0.87**
Qwen LoRA (train)	0.69	0.73	0.30	0.61	0.57	0.08
TF-IDF MLP (train)	**0.99**	**0.99**	0.84	**0.98**	**0.97**	0.18

Tabela 4.2. Porównanie Precision dla poszczególnych klas emocji

Model i Zbiór	sadness	joy	love	anger	fear	surprise
TF-IDF MLP (test)	0.88	0.89	0.66	0.89	0.85	**1.00**
DistilBERT (test)	**0.96**	**0.95**	**0.87**	**0.94**	**0.87**	0.75
Qwen Few-Shot (test)	0.73	0.69	0.38	0.47	0.35	0.09
Qwen LoRA (test)	0.61	0.72	0.47	0.66	0.60	0.00
DistilBERT (train)	0.98	0.97	**0.91**	**0.97**	0.94	0.85
Qwen LoRA (train)	0.61	0.68	0.48	0.69	0.64	0.96
TF-IDF MLP (train)	**0.99**	**0.99**	0.74	**0.97**	**0.96**	**1.00**

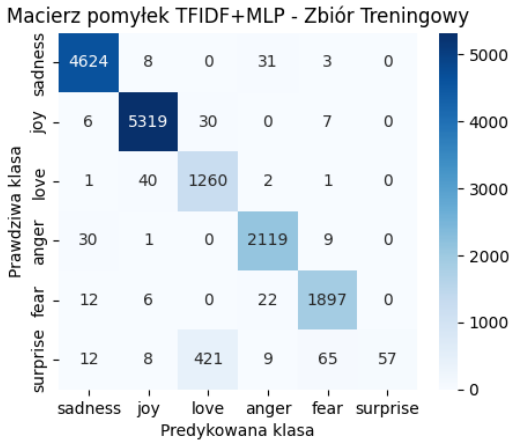
Tabela 4.3. Porównanie Recall dla poszczególnych klas emocji

Model i Zbiór	sadness	joy	love	anger	fear	surprise
TF-IDF MLP (test)	0.94	0.92	0.70	0.84	0.86	0.06
DistilBERT (test)	**0.97**	**0.96**	**0.84**	**0.90**	**0.90**	**0.76**
Qwen Few-Shot (test)	0.38	0.68	0.23	0.49	0.36	0.56
Qwen LoRA (test)	0.78	0.81	0.22	0.49	0.51	0.00
DistilBERT (train)	**0.99**	0.97	0.89	0.96	0.95	**0.89**
Qwen LoRA (train)	0.78	0.78	0.22	0.54	0.52	0.04
TF-IDF MLP (train)	**0.99**	**0.99**	**0.97**	**0.98**	**0.98**	0.10

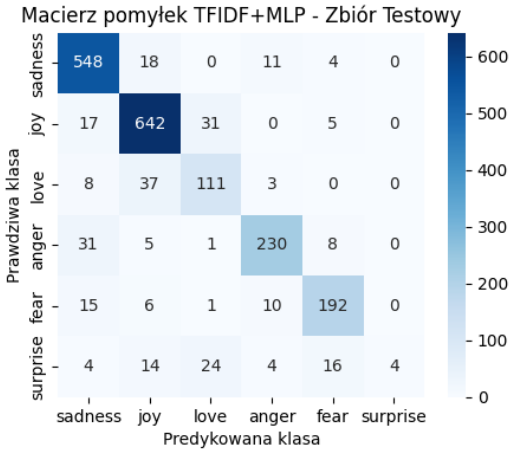
Tabela 4.4. Zbiorcze zestawienie wszystkich metryk zagregowanych (P-Precision, R-Recall)

Model i Zbiór	Accuracy	Macro P	Macro R	Macro F1	Weighted P	Weighted R	Weighted F1
TF-IDF MLP (test)	0.86	0.86	0.72	0.72	0.87	0.86	0.85
DistilBERT (test)	**0.93**	**0.89**	**0.89**	**0.89**	**0.93**	**0.93**	**0.93**
Qwen Few-Shot (test)	0.49	0.45	0.45	0.41	0.59	0.49	0.52
Qwen LoRA (test)	0.65	0.51	0.47	0.48	0.62	0.65	0.63
TF-IDF MLP (train)	0.95	**0.94**	0.83	0.82	**0.96**	0.95	0.94
Qwen LoRA (train)	0.65	0.68	0.48	0.50	0.65	0.65	0.62
DistilBERT (train)	**0.96**	**0.94**	**0.94**	**0.94**	**0.96**	**0.96**	**0.96**

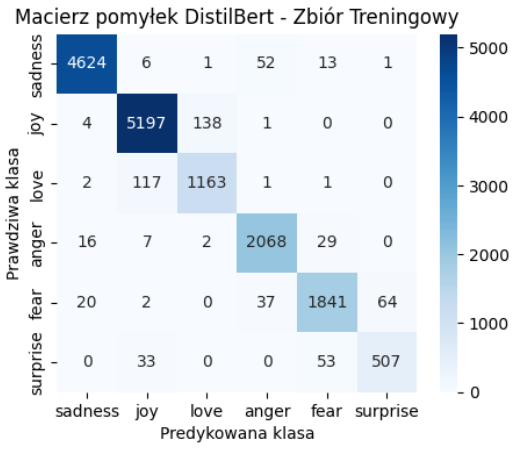
4.2. Macierze pomyłek



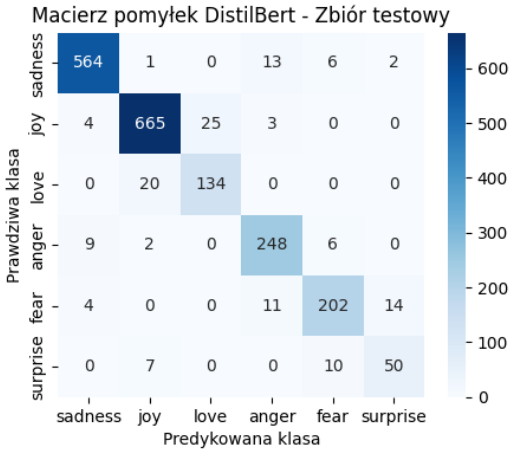
Rysunek 4.1. Macierz pomyłek TFIDF i MLP zbiór treningowy



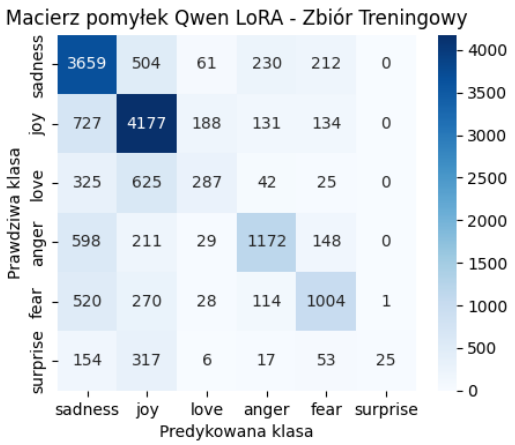
Rysunek 4.2. Macierz pomyłek TFIDF i MLP zbiór testowy



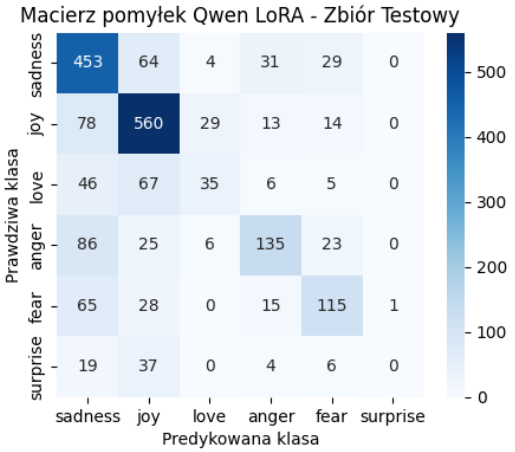
Rysunek 4.3. Macierz pomyłek DistilBERT zbiór treningowy



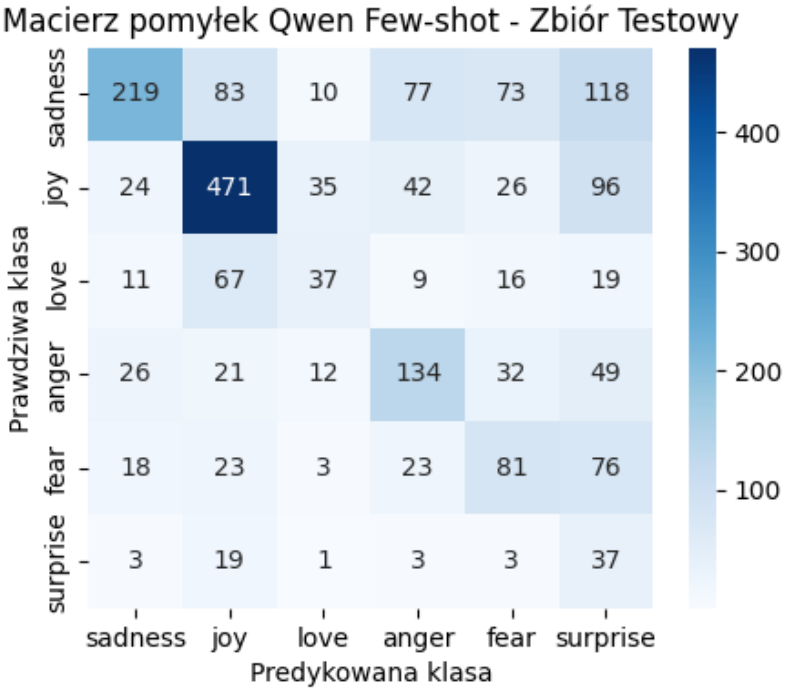
Rysunek 4.4. Macierz pomyłek DistilBERT zbiór testowy



Rysunek 4.5. Macierz pomyłek Qwen3 LoRA zbiór treningowy

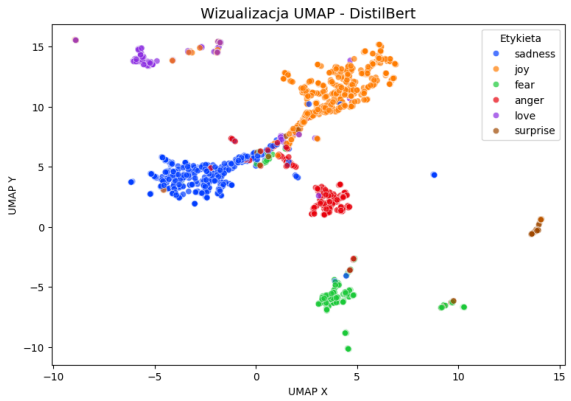


Rysunek 4.6. Macierz pomyłek Qwen3 LoRA zbiór testowy

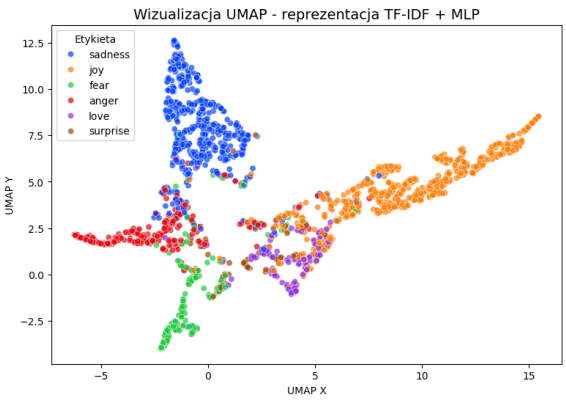


Rysunek 4.7. Macierz pomyłek Qwen3 few-shot prompting zbiór testowy

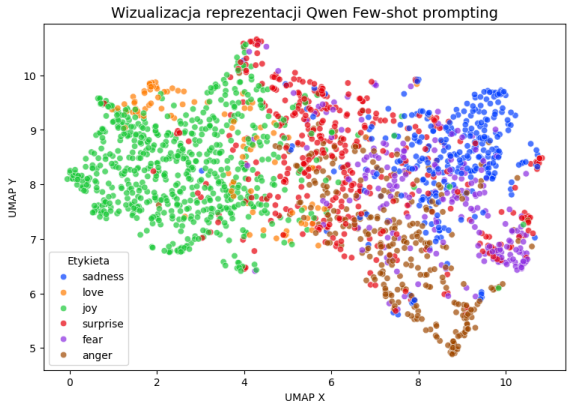
4.3. Wizualizacje reprezentacji metodą UMAP



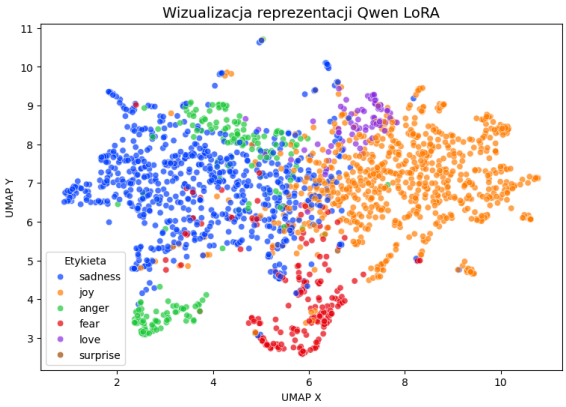
Rysunek 4.8. Wizualizacja reprezentacji DistilBERT



Rysunek 4.9. Wizualizacja reprezentacji TFIDF + MLP



Rysunek 4.10. Wizualizacja reprezentacji Qwen3 few-shot



Rysunek 4.11. Wizualizacja reprezentacji Qwen3 LoRA

4.4. Omówienie wyników

Najwyższą skuteczność spośród wszystkich badanych rozwiązań osiągnął model DistilBERT. Uzyskał on najwyższą dokładność na poziomie 0,93 dla zbioru testowego oraz 0,96 dla zbioru treningowego. Model MLP oparty na reprezentacjach TF-IDF, mimo że oparty na prostszej reprezentacji tekstowej, osiągnął bardzo solidny wynik na zbiorze testowym (Accuracy 0,86). Jest to wynik znacznie lepszy od obu wariantów modelu Qwen, co pokazuje, że klasyczne klasyfikacji tekstu wciąż mogą być bardzo konkurencyjne. Zastosowanie modelu tylko-dekoder (Qwen3-1.7B) przyniosło najgorsze wyniki ze wszystkich podejść.

- Few-shot prompting okazał się najsłabszą metodą (Accuracy 0,49). Model ten miał szczególny problem z rozróżnianiem klas innych niż joy co widać na wizualizacji UMAP - etykiety surprise, fear, sadness oraz anger są ze sobą mocno zmieszane.
- Dostrajanie metodą LoRA poprawiło wyniki względem promptingu (wzrost Accuracy do 0,65).

Największym wyzwaniem dla niemal wszystkich modeli okazała się klasa surprise, której przykładów było najmniej w zbiorach.

- DistilBERT poradził sobie z nią najlepiej (F1-score 0,75 na testowym).
- TF-IDF MLP mimo uzyskania 100% precyzji dla tej klasy na zbiorze testowym, wykazał skrajnie niski recall (0,06). Oznacza to, że model ten niemal nigdy nie przewiduje klasy surprise, a jeśli już to robi, to wyłącznie w sytuacjach, gdzie pewność jest absolutna.
- Qwen3 dostrajany metodą LoRA na zbiorze testowym całkowicie zignorował tę klasę (F1-score 0,00), co prawdopodobnie wynika z jej niskiej reprezentacji w zbiorze danych.

Emocje takie jak sadness oraz joy są rozpoznawane z najwyższą skutecznością, co prawdopodobnie spowodowane jest tym, że najczęściej występują w zbiorze.

5. Podsumowanie

Przeprowadzone badania nad klasyfikacją emocji w tekście pozwoliły na porównanie trzech różnych podejść: klasycznej metody opartej na reprezentacji wektorowej (TF-IDF z siecią MLP), modelu tylko-koder (DistilBERT) oraz modelu tylko-dekoder (Qwen3-1.7B).

Krótki i nieformalny charakter klasyfikowanych tekstów nie stanowił problemu dla dwóch pierwszych podejść, więc udało się rozwiązać postawiony problem. Najwyższą skuteczność osiągnął dostrojony model DistilBERT. Model ten poradził sobie nawet z rozpoznawaniem rzadziej występujących klas, takich jak surprise. Podejście oparte na TF-IDF i MLP również osiąga wysoki wyniki, jednak gorzej radzi sobie z klasami, które rzadziej występują w zbiorze. Wybrane metody dostrajania modelu Qwen3 okazały się nieskuteczne, model osiągnął najgorsze wyniki z porównywanych 3 podejść.

W ramach dalszego rozwoju projektu warto rozważyć wykorzystanie większych modeli z rodziny Qwen lub zastosowanie innych technik dostrajania.

Bibliografia

[1] E. Saravia, H.-C. T. Liu, Y.-H. Huang, J. Wu i Y.-S. Chen, „CARER: Contextualized affect representations for emotion recognition", w: *Proceedings of the 2018 conference on empirical methods in natural language processing*, 2018, s. 3687–3697.

[2] V. Sanh, L. Debut, J. Chaumond i T. Wolf, „DistilBERT, a distilled version of BERT: smaller, faster, cheaper and lighter", *arXiv preprint arXiv:1910.01108*, 2019.

[3] A. Yang i in., „Qwen3 technical report", *arXiv preprint arXiv:2505.09388*, 2025.